

LLM-агенты пишут GPU-ядра на незнакомом фреймворке

CuTe DSL и FP8: чему учит агента харнесс, когда
предобучение не помогает

Две грани одной проблемы

Незнакомый фреймворк

CuTe DSL для GPU-ядер: модель неплохо пишет Triton, но теряется в менее распространённых абстракциях. Нужен харнесс, подающий документацию, примеры и обратную связь по ходу работы.

Незнакомый числовой формат

Переход с FP16 на FP8 требует другой кодировки и специализированных инструкций — нужен харнесс для генерации FP8-кода и устойчивый замкнутый цикл разработки.

Оба направления измеряются одной линейкой: корректность, ускорение, число ходов агента, стоимость в токенах.

Изолированный харнесс для честной оценки

- Своя модель — Qwen3.6-35B-A3B (Q8_0) на 2×V100: слишком мала, чтобы знать CuTe DSL сама по себе, — всё, что она сделает, будет заслугой харнесса
- Оценка на NVIDIA B300 отделена от агента: генерацию входов, эталон на Torch, допуски и вердикт PASS владеет оценщик, а не модель
- Девять задач адаптированы из KernelBench под FP8-семантику — свои эталонные решения и пороги численного расхождения

02


Результаты

9 / 9

Задач решено за один независимый запуск агента — при полном стеке документации по CuTe DSL

Без документации агент не решает ни одной задачи — нижняя граница очевидна. Полный справочник переводит результат в качественно другую плоскость.

Решают примеры и типовые ошибки — не тексты про API



Успешные попытки из шести на каждом уровне документации (3 задачи × 2 мутации). Перелом наступает на конкретных примерах кода и описаниях типовых ошибок — не на прозе про API и архитектуру.

Эффект несут артефакты, а не объём текста

- API и архитектура сами по себе не сдвигают результат — 0 успешных попыток из 6 на каждом уровне
- Примеры кода дают первый перелом — 2 из 3 серий решены
- Типовые ошибки закрепляют результат — все 3 серии, 5 попыток из 6
- На уровнях без понимания модель пишет вдвое короче (229 токенов против 382) — быстрее сдаётся, а не дольше ошибается

Один параметр за раз, относительно лучшего уровня документации

ЭКСП.	ВОПРОС	ЧТО МЕНЯЕМ	PASS	УСКОР.	ТОКЕНЫ
E1	Какое знание важно	уровни документации × 3 задачи	—	—	—
E2	Стратегия извлечения	доставка files vs prompt	—	—	—
E3	Обратная связь: критик	агент-критик между ходами	—	—	—
E4	Обратная связь: профайлер	сводка профилировщика с B300	—	—	—

Три задачи второго уровня, шесть ходов на запуск — E1 задаёт опорную конфигурацию для E2–E4.

Харнесс важнее предобучения

Правильные примеры и разбор ошибок закрывают разрыв там, где тексты про API и архитектуру бессильны — дальше проверяем это на агентном режиме и второй ступени задач